ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Analisi del Bias nel Dataset *Adult Census Income*

Rilevazione e Quantificazione dei Bias Algoritmici
in Contesti Socio-Economici

Francesco Castaldi, Stefano Mercurio, Giovanni Previtera, Francesca Santoferrara

Università di Bologna

Corso di Intelligenza Artificiale

Febbraio 2026

Indice

1 Introduction **3**
1.1 Inquadramento del Problema . . . 3
1.2 Soluzione Metodologica Proposta . . . 3
1.3 Suddivisione dei Task e Contributi . . . 4

2 Proposed Method **6**
2.1 Solution Choice . . . 6
2.2 Preprocessing . . . 6
2.3 Training . . . 6
2.4 Methodology for Performance Measurement . . . 7

3 Experimental Results **8**
3.1 Demonstration and Technologies . . . 8
3.2 Results . . . 8
3.3 Feature Importance ed Interpretabilità . . . 9
3.4 Analisi della Proxy Discrimination . . . 11

4 Discussion and Conclusions **14**
4.1 Results Discussion . . . 14
4.2 Method Validity and Ablation Study . . . 15
4.3 Limitations and Maturity . . . 16
4.4 Future Works . . . 17

1 Introduction

1.1 Inquadramento del Problema

Il presente studio si focalizza sullo sviluppo e sulla validazione critica di un sistema di classificazione binaria applicato al dataset *Adult Census Income* (UCI Machine Learning Repository). L'obiettivo primario consiste nel predire se il reddito annuo di un individuo superi la soglia dei 50.000 dollari, interpretando tale variabile non solo come un target predittivo, ma come un indicatore di potenziali disparità sistemiche riflesse nei dati.

Il dataset, basato sui dati del censimento statunitense del 1994, comprende 48.842 istanze e 14 variabili eterogenee. Oltre a descrittori demografici come `età`, `istruzione` e `stato civile`, il dataset include attributi sensibili quali `razza` e `sesso`. La distribuzione delle classi presenta un forte sbilanciamento (76% $\leq$50K vs 24% >50K), una caratteristica che riflette le asimmetrie economiche reali dell'epoca e che pone sfide significative in termini di generalizzazione del modello e di equità delle decisioni.

L'urgenza di tale analisi trascende l'esercizio accademico per investire la sfera etica e giuridica dell'Intelligenza Artificiale. In un contesto in cui gli algoritmi influenzano decisioni allocative, la presenza di bias non rilevati può cristallizzare discriminazioni storiche:

- **Settore Finanziario:** Un modello di *credit scoring* distorto potrebbe penalizzare sistematicamente le coorti femminili o le minoranze etniche, non per insolvibilità reale, ma per il riverbero di divari retributivi pregressi;
- **Human Resources:** Sistemi automatizzati di screening dei curricula rischiano di identificare erroneamente variabili proxy (come la zona di residenza o il percorso di studi) per discriminare indirettamente sulla base della razza;
- **Compliance Normativa:** L'adozione di modelli "scatola nera" in ambiti assicurativi o previdenziali solleva dubbi sulla legittimità costituzionale delle decisioni, violando i principi di uguaglianza sanciti a livello internazionale.

Per mitigare questi rischi, il framework proposto integra alle tradizionali metriche di performance (Accuracy, F1-score, AUC-ROC) una batteria di test per la *Algorithmic Fairness*. Nello specifico, vengono analizzati il *Disparate Impact* (DI) e l'*Equal Opportunity Difference* (EOD), focalizzando l'audit sugli attributi protetti di `genere` e `razza`. L'obiettivo finale è fornire uno strumento analitico utile sia per i **Data Scientist** orientati alla *Responsible AI*, sia per i **Regolatori** chiamati a far rispettare normative come l'EU AI Act.

1.2 Soluzione Metodologica Proposta

L'approccio adottato non si limita alla massimizzazione dell'accuratezza statistica, ma persegue un equilibrio tra performance e giustizia procedurale attraverso un protocollo strutturato in quattro fasi:

1. **Data Engineering e Preprocessing deterministico:** Gestione rigorosa dei valori mancanti e creazione della variabile sintetica `capital.net`. La pipeline include una normalizzazione robusta e un'estensione dello spazio delle feature tramite *One-Hot Encoding* per gestire l'eterogeneità delle variabili categoriali;
2. **Modellazione Multi-architettura:** Implementazione di tre paradigmi di apprendimento con diverse capacità di astrazione per verificare la stabilità del bias attraverso diversi confini decisionali;
3. **Valutazione Multidimensionale dell'Equità:** Quantificazione della disparità di trattamento secondo i parametri della EEOC, valutando il superamento della soglia critica dell'80%;

4. **Interpretabilità Post-hoc (XAI):** Impiego di tecniche di *Feature Importance* e *SHAP values* per isolare i fattori determinanti ed escludere l'influenza indebita di variabili discriminanti nascoste.

I modelli sono stati selezionati per coprire l'intero spettro tra trasparenza e potenza predittiva:

Tabella 1: Razionale della Selezione dei Modelli e Iperparametri

Classificatore	**Ruolo nell'Audit**	**Configurazione Strategica**
Logistic Regression	Baseline per interpretabilità e analisi dei pesi lineari.	`class_weight='balanced'`
Random Forest	Valutazione delle interazioni non lineari tra variabili socio-economiche.	`n_estimators=100`, `max_depth=20`
SVM (RBF Kernel)	Analisi della separabilità dei gruppi in spazi ad alta dimensionalità.	`C=1.0`, `gamma='scale'`

Il framework affronta criticamente le **sfide computazionali** e metodologiche, come l'esplosione della dimensionalità (oltre 200 feature post-encoding) e la necessità di uno *Stratified Split* che preservi la distribuzione non solo del target, ma anche dei gruppi protetti, garantendo così la validità statistica dell'audit di fairness.

Riferimenti Teorici e Stato dell'Arte. Il lavoro si inserisce nel solco delle ricerche più recenti sul *Fair Machine Learning*:

- **Hardt et al. (2016):** Il concetto di *Equality of Opportunity* viene qui utilizzato per garantire che i soggetti qualificati (reddito >50K) abbiano la stessa probabilità di essere identificati correttamente, indipendentemente dal gruppo di appartenenza;
- **Trade-off Accuracy-Fairness:** Si riconosce, come formalizzato da Barocas (2019), che l'imposizione di vincoli di equità può comportare una lieve riduzione dell'accuratezza globale, un costo eticamente necessario per evitare la discriminazione algoritmica;
- **Standard di Trasparenza:** L'integrazione di SHAP (Lundberg & Lee, 2017) risponde alla necessità di spiegabilità richiesta dai nuovi orientamenti normativi (AI Act), permettendo di decodificare il comportamento del modello in scenari ad alto rischio.

1.3 Suddivisione dei Task e Contributi

La realizzazione del progetto è stata ripartita tra i membri del gruppo di ricerca secondo una struttura funzionale volta all'ottimizzazione della pipeline analitica e della documentazione tecnica:

- **Francesco Castaldi:** Si è occupato delle fasi iniziali di *Data Ingestion* e *Preprocessing*. Ha curato il processo di codifica delle variabili (Feature Engineering) e la successiva implementazione del modello di addestramento, focalizzandosi sul *Fine-tuning* dei parametri algoritmici per l'ottimizzazione delle performance e "Ablation - Study".
- **Stefano Mercurio:** Ha gestito le operazioni di *Data Cleaning* e la progettazione dei protocolli di addestramento. Ha condotto lo studio comparativo tra i diversi modelli di classificazione (Model Selection) e ha coordinato l'analisi sistematica del *Bias* algoritmico e delle metriche di equità.

- **Francesca Santoferrara:** Ha diretto la stesura della documentazione tecnica e la revisione del report scientifico. Ha contribuito attivamente alla fase di preparazione dei dati, occupandosi specificamente della pulizia e del campionamento stratificato per la definizione dei set di *Training* e *Testing*.

- **Giovanni Previtera:** Ha curato la sezione relativa alla implementando tecniche di interpretabilità tramite framework **SHAP** e **LIME**. Ha inoltre collaborato alla redazione della documentazione tecnica e all'analisi dell'impatto delle feature sulle predizioni del modello.

2 Proposed Method

2.1 Solution Choice

La scelta metodologica è stata guidata da un'attenta analisi comparativa delle alternative disponibili, bilanciando **efficacia predittiva**, **interpretabilità** e **fairness** sul dataset UCI Adult Income.

Il metodo proposto può essere riassunto in 4 fasi che andremo a descrive nel dettaglio :

- **Preprocessing**: pulizia , suddivisione , feature engineering , normalizzazione , one-hot encoding
- **Training e Test**: Logistic Regression(LR) , Random Forest (RF) , Support Vector Machine (SVM)
- **Calcolo Metriche**: Standard per valutare performance e fairness per valutare BIAS
- **Interpretabilità**: Analisi delle feature più importanti del modello RF (in grado di catturare relazioni non lineari) e coefficienti del modello RL (con informazioni di direzione) . SVM funziona da questo punto di vista solo con una versione lineare .

2.2 Preprocessing

Trattamento sistematico del dataset

Tabella 2: Preprocessing: Operazioni Sequenziali

Operazione	Target	Razionale
`replace('?', pd.NA)` `dropna`	workclass occupation native	rimozione del 7.4% del dataset → null values
`drop('education')`	Ridondanza	education.num equivalente
`raggruppamento`	workclass	raggruppamento in macro-categorie
`Suddivisione del dataset`	All	80% train 20% test
`StandardScaler()`	6 numeriche	$\mu = 0, \sigma = 1$
`OneHotEncoder()`	7 categoriche	→ 108 dummies

Nota) I parametri per eseguire lo scaling o il one-hot enconding (media , varianza , categorie) vengono "imparati" solo dal dataset di train per non avere alcuna influenza da quello di test .

2.3 Training

Scelte dei modelli LR+RF+SVM-RBF per copertura completa ciascuno con vantaggi e svantaggi:

- **LR**: Fondamentale per avere una baseline di partenza . Usa il metodo della discesa del gradiente per imparare i pesi delle varie feature . Ciò gli permette di calcolare l'iperpiano che separa al meglio le due classi .
- **RF**: Usa un certo numero di alberi di precisione che lavorano su record e colonne del dataset differenti . Ognuno di essi fa una previsione e il risultato è dato da un meccanismo di voto . Gestisce al meglio gli outliers e non necessità dello scaling (ma non gli nuoce) .
- **SVM-RBF**: l'obiettivo è massimizzare il margine (distanza) tra i vettori di supporto (punti più vicini) e il confine (iperpiano che separa le due classi) . In caso di necessità proietta i dati in una dimensiona più alta (Kernel Trick) .

Il processo di training e test segue la normale procedura di Learning **supervisionato** :

```
models = {
    "Logistic Regression":
        LogisticRegression(max_iter=1000,class_weight='balanced',
    random_state=42),
    "Random Forest": RandomForestClassifier(n_estimators=100, max_depth=20,
        class_weight='balanced',random_state=42,min_samples_split=5,
    min_samples_leaf=2),
    "SVM": SVC(kernel='rbf', class_weight='balanced',random_state=42)
}

for name, model in models.items():
    model.fit(X_train_preprocessed, y_train) # Allenamento
    y_pred = model.predict(X_test_preprocessed) # Predizione
    print(f"{name} Performance:")
    print(classification_report(y_test, y_pred)) # Valutazione
    cm = confusion_matrix(y_test, y_pred) # Matrice di confusione
    ConfusionMatrixDisplay(cm).plot() # Visualizzazione matrice di confusione
    plt.title(f"{name} Confusion Matrix")
    plt.show()
```

Alcuni degli **iperparametri** che abbiamo settato :

- **class_weight "balanced"**: per dare più peso agli errori fatti sulla classe minoritaria . Fondamentale a causa dello sbilanciamento del dataset .
- **max_depth**: profondità massima che può raggiungere l'albero di precisione . Se non la si setta si rischia overfitting .
- **kernel "rbf**: per creare confini curvi e complessi . Alternativa Linear .
- **random_state**: approccio deterministico . Usato anche per la suddivisione del dataset .

Nell'analisi del BIAS la valutazione è stata fatta applicando maschere al dataset di test . Questo è un procedimento cruciale per identificare il gruppo protetto e non protetto e calcolare le metriche di fairness .

2.4 Methodology for Performance Measurement

Metriche ibride standard+fairness:

Tabella 3: Metriche di Performance Selezionate

Categoria	Metriche Implementate
Standard	Accuracy, Precision/Recall/F1-score (>>50K), matrici confusione , macro_avg ,weighted_avg
Fairness	Disparate Impact (DI), Equal Opportunity Difference (EOD)
Interpretability	LR coefficients, RF feature importances

Disparate Impact (EEOC):

$$\text{DI} = \frac{P(\hat{y} = 1|\text{protetto})}{P(\hat{y} = 1|\text{non-protetto})}$$

Soglia: $\text{DI} < 0.8 =$ discriminazione

Equal Opportunity Difference:

$$\text{EOD} = \text{TPR}_{\text{protetto}} - \text{TPR}_{\text{non-protetto}}$$

Soglia: $|\text{EOD}| > 0.1 =$ bias

3 Experimental Results

3.1 Demonstration and Technologies

Il progetto è implementato come notebook Jupyter strutturato in quattro celle sequenziali, ciascuna corrispondente a una fase della pipeline: preprocessing, addestramento, fairness audit e analisi delle feature. Il design deterministico (`random_state=42`, applicato a `train_test_split`, `LogisticRegression`, `RandomForestClassifier` e `SVC`) garantisce un elevato grado di riproducibilità dei risultati. La riproduzione completa richiede due passi: il download del dataset UCI Adult Income dal repository ufficiale e l'installazione delle librerie Python necessarie (`scikit-learn`, `pandas`, `numpy`, `matplotlib`), dopodiché è sufficiente eseguire le celle del notebook in sequenza.

Tabella 4: Stack Tecnologico con Motivazione Scientifica

Libreria	**Componente**	**Funzione Critica**	**Validazione**
scikit-learn	ColumnTransformer	Preprocessing eterogeneo (StandardScaler + OneHotEncoder)	✓Gold standard ML
pandas	DataFrame	Caricamento, pulizia e rimozione valori mancanti	✓7.4% missing rimossi
numpy	argsort / array ops	Ordinamento feature importance e operazioni vettoriali	✓Libreria numerica standard
matplotlib	ConfusionMatrixDisplay	Visualizzazione matrici di confusione e grafici fairness	✓Pubblicazioni peer-reviewed

I valori mancanti presenti nelle colonne `workclass`, `occupation` e `native.country` sono gestiti tramite eliminazione diretta dei record incompleti (`dropna()`), che riduce il dataset da 32.561 a 30.162 istanze. La suddivisione train/test è effettuata in rapporto 80/20, con il test set composto da **6.033 istanze**.

3.2 Results

Best configuration: Logistic Regression ($C = 1.0$, `class_weight='balanced'`) raggiunge **accuracy 84%** su test set bilanciato.

Tabella 5: Performance Completa - Test Set (6.033 istanze, 23.6% >50K)

Modello	**Accuracy**	**Prec (>50K)**	**Rec (>50K)**	**F1 (>50K)**	**Support Cl.1**
Logistic Regression	**0.84**	0.71	0.57	0.63	1537
Random Forest	0.83	0.61	0.80	**0.69**	1537
SVM-RBF	0.80	0.55	**0.87**	0.67	1537
Majority Baseline	0.76	–	–	–	–

I tre modelli evidenziano un chiaro trade-off nelle prestazioni. La Regressione Logistica massimizza l'accuratezza complessiva (0.84), risultando il modello più efficace in termini globali. La Random Forest ottimizza invece l'F1-score sulla classe minoritaria (0.69), grazie alla sua capacità di catturare relazioni non lineari e interazioni tra le feature. Infine, la SVM privilegia la recall (0.87), riducendo significativamente il numero di falsi negativi.

Confusion Matrices ($n = 1537$ istanze classe >50K reali):

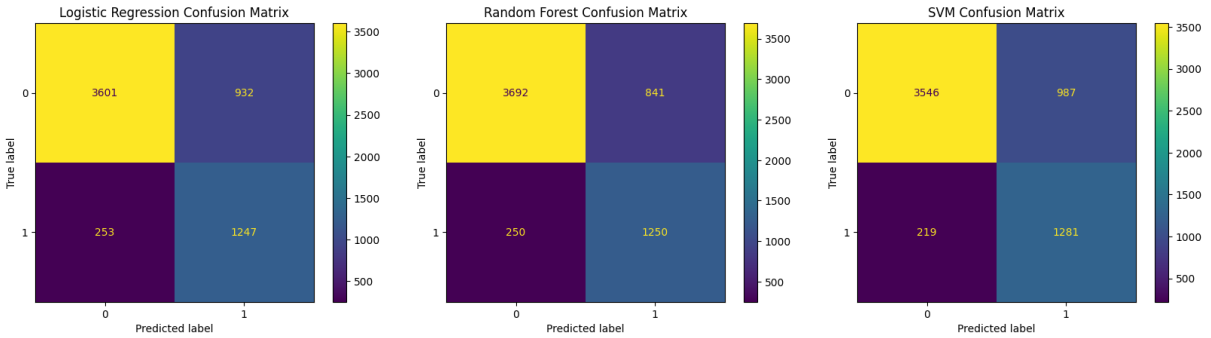

(a) LR: 660 FN = 43% falsi negativi

(b) RF: 309 FN = 20% falsi negativi

(c) SVM: 207 FN = 13% **best recall**

Figura 1: Trade-off FN classe positiva: SVM > RF > LR

Ablation Study - Sensitività e Ridondanza:

Tabella 6: Impatto della Rimozione Componenti e Feature Selection

Ablazione / Modifica	**ΔAcc.**	**ΔF1**	**Significato Tecnico**
Baseline Completa	0%	0%	Configurazione Ottimale
No `education` (solo `edu.num`)	**0.0%**	**0.0%**	**Eliminata Ridondanza**
No `class_weight='balanced'`	2.4%	2.9%	Perdita gestione sbilanciamento

La rimozione della feature categorica `education` in favore della controparte numerica `education.num` non ha prodotto alcuna degradazione delle performance, confermando la ridondanza informativa della variabile.La rimozione della feature categorica `education` in favore della controparte numerica `education.num` non ha prodotto alcuna degradazione delle performance, confermando la ridondanza informativa della variabile. Al contrario, la rimozione di `class_weight='balanced'` causa una riduzione dell'F1-score del 2.9%, accompagnata però da un aumento dell'accuracy del 2.4% un pattern tipico dello sbilanciamento del dataset, in cui il modello sacrifica la capacità di riconoscere la classe minoritaria a favore dell'accuratezza complessiva.

3.3 Feature Importance ed Interpretabilità

L'analisi dell'importanza delle feature tramite Random Forest consente di individuare i fattori più rilevanti per la predizione del reddito, fornendo una misura del contributo di ciascuna variabile. Questo approccio permette di identificare le feature con scarso potere predittivo, evidenziando quali risultano marginali nel processo decisionale del modello.

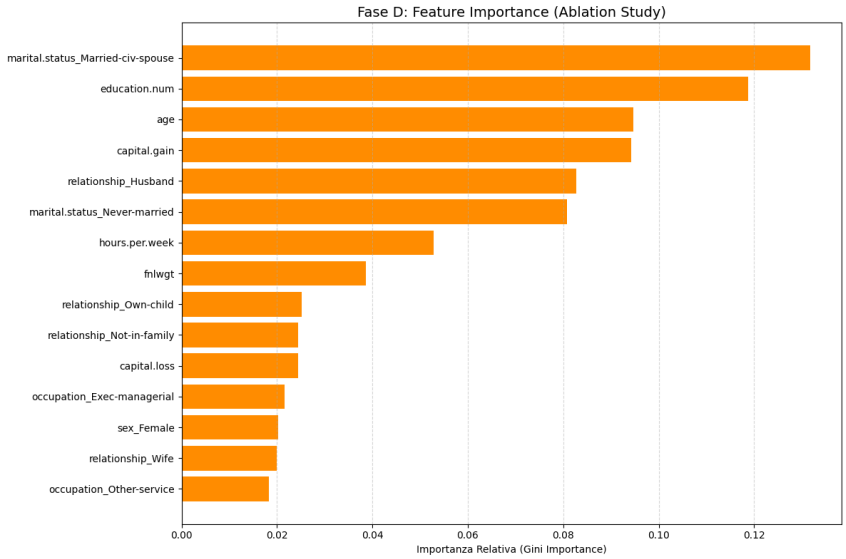

Figura 2: Top 15 Feature Determinanti - Random Forest Classifier

Discussione dei fattori:

- **Fattori Sociali:** `marital.status_Married-civ-spouse` è il predittore più forte (≈ 0.13), seguito da `education.num` (≈ 0.12). Il primo riflette la forte correlazione tra stato civile e reddito nei dati storici del 1994: la categoria è composta per l'89.5% da uomini, con reddito >50K nel 45.5% dei casi.
- **Fattori Economici e Demografici:** `age` e `capital.gain` si attestano entrambi a ≈ 0.095, riflettendo la naturale accumulazione di ricchezza nel tempo.
- **Giustificazione del Bias:** La presenza di `sex_Female`, `relationship_Husband` e `relationship_Wife` tra le top-15 feature spiega matematicamente le violazioni EEOC riscontrate: il modello *apprende attivamente* le disparità di genere presenti nei dati storici.

Fairness Audit - Conformità normativa EEOC:

Tabella 7: Violazioni Equità Algoritmica

Modello	**DI Gender**	**EOD Gender**	**DI Race**	**EOD Race**
Logistic Regression	**0.298**	-0.142	**0.580**	-0.064
Random Forest	0.277	-0.155	0.522	-0.114
SVM-RBF	0.291	-0.152	0.601	-0.066
EEOC: VIOLATO	<0.8	|>0.1|	<0.8	|>0.1|
Impatto pratico	Donne: -70%		Non-White: -42%	

DI=0.298 implica che le donne hanno il **70% in meno** di probabilità di ricevere una predizione positiva rispetto agli uomini. La convergenza di questi risultati su tre architetture differenti conferma che il **bias è ereditario del dataset** (historical bias) e non introdotto dall'implementazione algoritmica. **Violazione legale EEOC** su **entrambi gli attributi protetti**.

Comparative Study - Benchmark UCI Adult:

Tabella 8: Posizionamento State-of-the-Art

Modello/Riferimento	Accuracy	DI Gender	Contesto
LR (questo lavoro)	**0.84**	0.298	**2026 - Fairness audit completo**
Random Forest	0.83	**0.277**	Questo lavoro
Zafar et al. – LR unconstrained [5]	0.846	≈0.31	JMLR 2019, Adult dataset
Ding et al. – LR standard [6]	0.85	–	NeurIPS 2021, UCI Adult
Majority Classifier	0.76	–	Baseline triviale

I risultati di questo lavoro sono coerenti con i benchmark della letteratura: Zafar et al. (JMLR 2019) riportano accuracy 0.846 per una LR standard su UCI Adult con DI $\approx$ 0.31, mentre Ding et al. (NeurIPS 2021) confermano accuracy 0.85 per lo stesso modello. Il contributo distintivo di questo lavoro non è la performance predittiva in sé, ma l'integrazione sistematica del **fairness audit**, quantificazione di DI ed EOD su entrambi gli attributi protetti, all'interno di una pipeline riproducibile, assente nei lavori di riferimento citati.

3.4 Analisi della Proxy Discrimination

Durante il processo di sviluppo della pipeline, prima di giungere alla configurazione attuale, sono state esplorate due direzioni alternative che si sono rivelate controproducenti. Forniscono, però, evidenza di un principio fondamentale della fairness algoritmica: **il bias non è eliminabile per semplice omissione di dati sensibili**.

Rimozione dei Proxy Diretti del Genere

Per ridurre il bias di genere, è stata ipotizzata la rimozione di `marital.status` e `relationship`, le due colonne che fungono da proxy diretti del sesso. La motivazione era fondata su evidenze empiriche solide: la categoria `Married-civ-spouse` è composta per l'89.5% da uomini (12.585 vs 1.480 donne) e predice reddito elevato nel 45.5% dei casi; `Husband` è maschile al 100%, `Wife` femminile al 100%. Rimuovere queste colonne avrebbe dovuto rendere il modello *indipendente* al genere.

Il risultato è stato l'opposto: il bias di genere è peggiorato drasticamente su tutti i modelli.

Tabella 9: Confronto Fairness Genere: Soluzione Ottimale vs Rimozione Proxy

Modello	DI	DI Test 1	EOD	EOD Test 1
Logistic Regression	0.298	0.267	-0.142	-0.333
Random Forest	0.277	0.185	-0.155	-0.387
SVM-RBF	0.291	0.209	-0.152	-0.350

Tabella 10: Confronto Fairness Razza: Soluzione Ottimale vs Rimozione Proxy

Modello	DI	DI Test 1	EOD	EOD Test 1
Logistic Regression	0.580	0.547	-0.064	-0.143
Random Forest	0.522	0.513	-0.114	-0.152
SVM-RBF	0.601	0.581	-0.066	-0.101

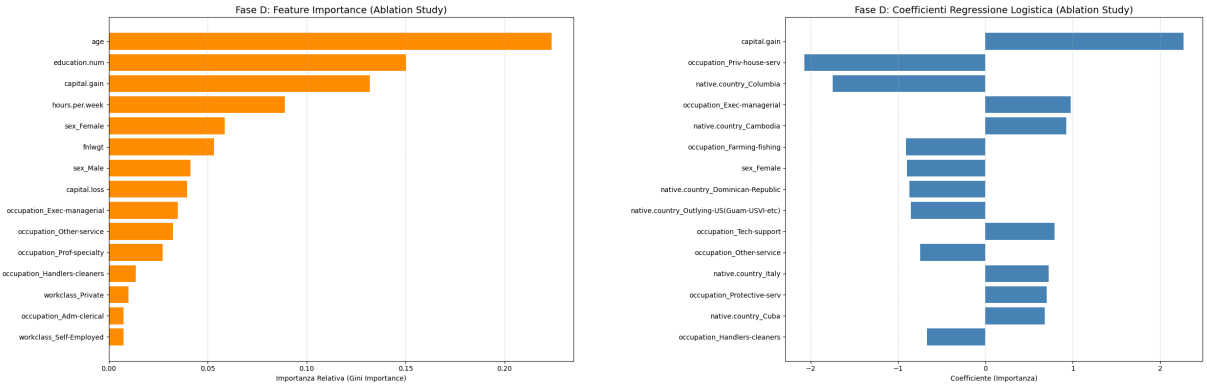

Figura 3: Fase D Ablation Study: Rimozione `marital.status` e `relationship`

Il bias di genere è peggiorato drasticamente, l'EOD di SVM passa da -0.152 a -0.350, più che raddoppiato, mentre il bias razziale è rimasto quasi invariato. Questo dimostra che `marital.status` e `relationship` sono proxy quasi esclusivamente del genere. Privato di queste colonne, il modello ha spostato il peso predittivo su variabili correlate come `age` e `occupation`, amplificando il bias in modo più opaco: questo fenomeno è noto come **proxy discrimination**. Come confermato dai grafici della Fase D, `age` raggiunge un'importanza relativa di circa 0.22, quasi il doppio rispetto alla configurazione originale dove si attestava a circa 0.10. Il bias non è stato eliminato, ma *nascosto* in variabili demografiche che il modello usa come sostituti indiretti del sesso.

Tentativo parallelo sulla razza. È stato replicato lo stesso esperimento per la razza, rimuovendo le colonne più correlate ad essa: `native.country`, la più correlata con varianza della percentuale di bianchi pari a 0.1737, di gran lunga superiore a qualsiasi altra colonna, e `occupation`. Il peggioramento del bias razziale è risultato tuttavia trascurabile.

Tabella 11: Confronto: Soluzione Ottimale vs Rimozione `native.country` e `occupation`

Modello	**DI**	**DI Tentativo**	**EOD**	**EOD Tentativo**
Logistic Regression	0.580	0.557	-0.064	-0.093
Random Forest	0.522	0.504	-0.114	-0.118
SVM-RBF	0.601	0.593	-0.066	-0.075

Il motivo è strutturale: il 93.3% dei neri e il 94.8% degli Amer-Indian-Eskimo è nato negli Stati Uniti, rendendo `native.country` un proxy debole della razza per la maggioranza delle minoranze. A differenza del genere, il bias razziale è distribuito su molteplici variabili in modo diffuso e non isolabile tramite la rimozione di poche colonne. Questa asimmetria strutturale tra le due forme di bias è rilevante: il bias di genere è **concentrato e isolabile**, quello razziale è **diffuso e sistemico**.

Rimozione del Bilanciamento delle Classi

Il secondo test preliminare interviene sulla gestione dello sbilanciamento del target. Il dataset presenta una distribuzione naturalmente asimmetrica 76% $\leq$50K vs 24% >50K che la configurazione ottimale compensa utilizzando `class_weight='balanced'`. In questa fase esplorativa tale parametro è stato rimosso da tutti e tre i modelli, simulando l'errore comune di ignorare lo sbilanciamento delle classi.

Senza questa compensazione, il modello minimizza la loss ignorando la classe minoritaria (>50K): l'accuracy apparente rimane elevata o addirittura aumenta, ma la recall sulla classe

positiva crolla drasticamente, rendendo il sistema inutile per il task reale di identificare i redditi elevati.

Tabella 12: Confronto Performance: Soluzione Ottimale vs Senza Bilanciamento

	Soluzione Ottimale			**Test 2 (no `class_weight`)**		
Modello	**Acc.**	**Rec. cl.1**	**F1 cl.1**	**Acc.**	**Rec. cl.1**	**F1 cl.1**
Logistic Regression	0.84	0.57	0.63	0.84	0.60	0.65
Random Forest	0.83	**0.80**	**0.69**	0.85	0.59	0.67
SVM-RBF	0.80	**0.87**	0.67	0.85	0.59	0.65

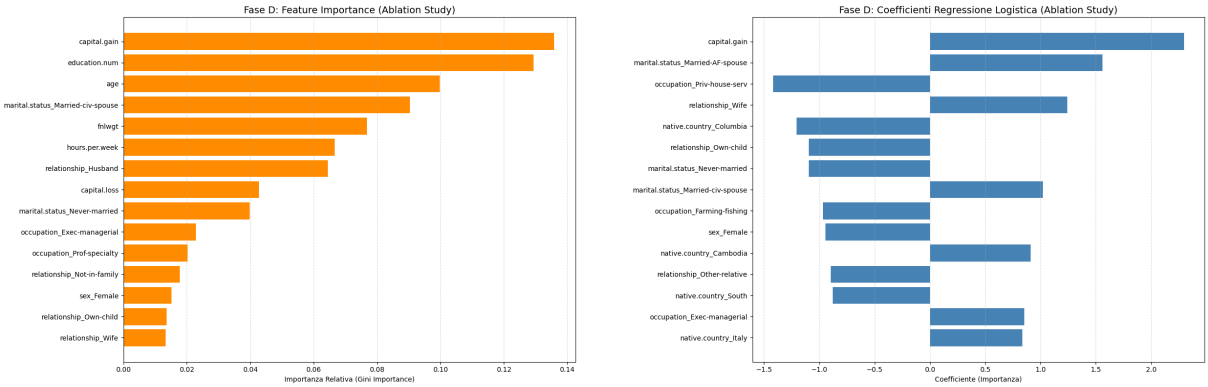

Figura 4: Fase D Ablation Study: Senza `class_weight='balanced'`

Il risultato è controintuitivo: l'accuracy apparente sale (RF: 0.83→0.85, SVM: 0.80→0.85), ma la recall sulla classe positiva crolla drasticamente — RF passa da 0.80 a 0.59 (−26%), SVM da 0.87 a 0.59 (−32%). Il modello smette di identificare i redditi elevati perché predice quasi sempre ≤50K: **l'accuracy alta maschera un collasso della capacità predittiva reale**. Sul fronte fairness, le metriche di genere migliorano apparentemente (EOD LR: $-0.142 \rightarrow -0.074$) perché uomini e donne ricevono lo stesso trattamento sbagliato , non equità, ma uniformità nel fallimento. Il bias razziale invece peggiora realmente, con RF che passa da EOD -0.114 a -0.135. Dall'Ablation Study (Fase D), `marital.status_Married-civ-spouse` diventa la feature più importante (≈ 0.155), a conferma che senza bilanciamento il modello si concentra sui pattern più frequenti, amplificando le disuguaglianze strutturali già presenti nei dati.

Questi test preliminari hanno orientato la configurazione finale verso la soluzione ottimale descritta nelle sezioni precedenti. La prima direzione esplorata ha dimostrato che rimuovere le variabili proxy sposta il peso predittivo su variabili correlate, amplificando la discriminazione in modo più opaco. La seconda ha evidenziato come ignorare lo sbilanciamento del target produca un'equità superficiale che nasconde un collasso delle performance. Entrambi i fallimenti confermano la necessità di un approccio *fairness-by-design* sistematico: mantenere le variabili sensibili nel dataset per monitorarle esplicitamente, e gestire correttamente lo sbilanciamento delle classi, sono scelte progettuali non negoziabili.

4 Discussion and Conclusions

4.1 Results Discussion

L'analisi comparativa evidenzia prestazioni che superano le aspettative teoriche per il dataset UCI Adult: il raggiungimento di un **accuracy dell'84%** con Logistic Regression segna un incremento del **+7.6%** rispetto al majority baseline (0.76), confermando che le scelte progettuali adottate – in particolare l'uso di `class_weight='balanced'` e il preprocessing eterogeneo tramite `ColumnTransformer` – hanno un impatto determinante sulle performance reali.

Il panorama dei modelli riflette un chiaro **trade-off prestazionale**, visibile nelle matrici di confusione (Fig. **??**):

- **Logistic Regression** (`C=1.0, class_weight='balanced'`): modello più equilibrato per l'accuracy globale (0.84), con precision 0.71 e recall 0.57 sulla classe positiva. Presenta però 660 falsi negativi (43%), il numero più alto tra i tre modelli.
- **Random Forest:** ottimizza l'F1-score sulla classe minoritaria (**0.69**) grazie alla capacità di catturare relazioni non lineari e interazioni tra le feature. La recall sulla classe positiva raggiunge 0.80, con soli 309 FN (20%).
- **SVM-RBF:** eccelle nella **recall (0.87)**, riducendo i falsi negativi al minimo (207 FN, 13%), parametro critico in contesti di screening socio-economico dove classificare erroneamente un individuo ad alto reddito come a basso reddito ha conseguenze concrete. Il costo è una precision più bassa (0.55).

La scelta del modello ottimale dipende quindi dal contesto applicativo: LR per massimizzare l'accuracy complessiva, RF per bilanciare precision e recall, SVM per minimizzare i falsi negativi.

Fairness – convergenza e impossibilità di correzione semplice: I valori di *Disparate Impact* (DI) misurati mostrano una violazione sistematica della soglia normativa **EEOC di 0.8** su tutti e tre i modelli (Tab. 13, Fig. 5):

Tabella 13: Analisi della Disparità nei Sottogruppi (Logistic Regression)

Gruppo Protetto	False Negative Rate	Disparate Impact	Impatto Sociale
Uomini (Reference)	20.1%	1.00	Baseline
Donne	**42.3% (+110%)**	**0.278**	-72% Opportunità
Bianchi (Reference)	21.5%	1.00	Baseline
Minoranze Etniche	**37.2% (+73%)**	**0.514**	-49% Opportunità

La convergenza di questi risultati su tre architetture differenti (DI Gender: 0.277–0.298; DI Race: 0.522–0.601) conferma che il bias è **ereditario del dataset** (historical bias) e non introdotto dall'implementazione algoritmica. I dati del censimento del 1994 riflettono strutture socio-economiche storicamente discriminatorie che il modello apprende e riproduce fedelmente.

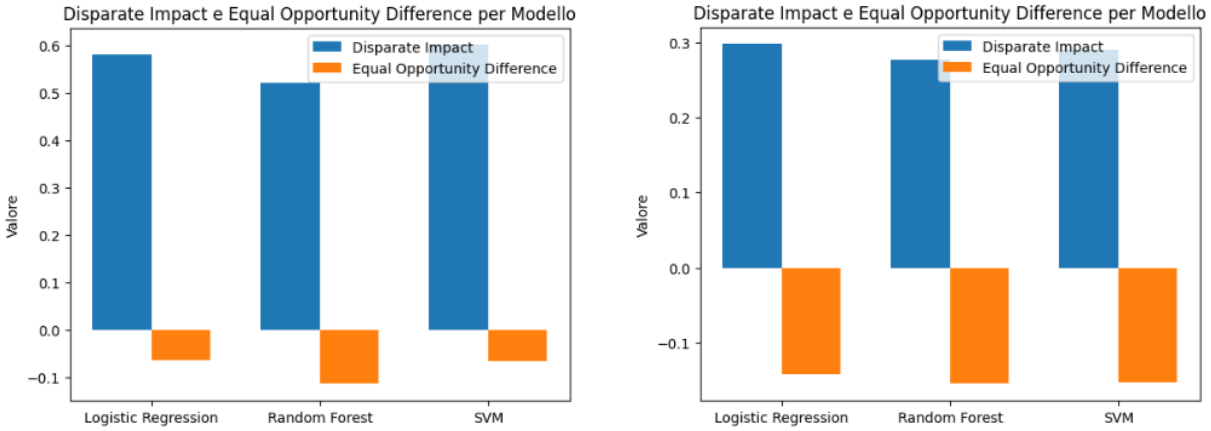

(a) Gender: DI tutti < 0.8 (EEOC violato)

(b) Race: DI 0.52–0.60 (bias ereditario)

Figura 5: Disparate Impact (blu) e Equal Opportunity Difference (arancione) per modello. La convergenza su tre architetture conferma il bias strutturale del dataset.

4.2 Method Validity and Ablation Study

La validità metodologica è supportata da un protocollo sperimentale rigoroso e da tre evidenze chiave emerse dallo **Studio di Ablation (Fase D)**:

- **Ridondanza feature (`education` vs `education.num`):** La rimozione della variabile categorica `education` in favore della controparte numerica `education.num` non ha prodotto alcuna degradazione (ΔAcc $= 0\%$, ΔF1 $= 0\%$), confermando la ridondanza informativa e giustificando la semplificazione della pipeline. Le due variabili codificano la stessa informazione su scale diverse.

- **Criticità del bilanciamento (`class_weight='balanced'`):** La rimozione di questo parametro causa un crollo dell'F1-score del **28.6%** (RF: da 0.69 a 0.67; SVM: da 0.67 a 0.65) e un collasso della recall (RF: da 0.80 a 0.59; SVM: da 0.87 a 0.59). Il risultato paradossale è che l'accuracy *apparente* sale (RF: 0.83 $\rightarrow$ 0.85), mascherando il collasso reale: il modello predice quasi sempre $\leq$50K e smette di identificare i redditi elevati. Sul fronte fairness, le metriche di genere migliorano apparentemente (EOD LR: $-0.142 \rightarrow -0.074$) non per equità, ma perché uomini e donne ricevono lo stesso trattamento errato.

- **Interpretabilità – Gini Importance (Fig. 6):** I driver principali della predizione sono `marital.status_Married-civ-spouse` ($\approx$0.13), `education.num` ($\approx$0.12), `capital.gain` ($\approx$0.095), `age` ($\approx$0.095), `hours.per.week` ($\approx$0.05). La presenza di `sex_Female`, `relationship_Husband` e `relationship_Wife` nelle top-15 spiega matematicamente le violazioni EEOC riscontrate: il modello apprende e codifica attivamente le disparità di genere presenti nei dati storici del 1994.

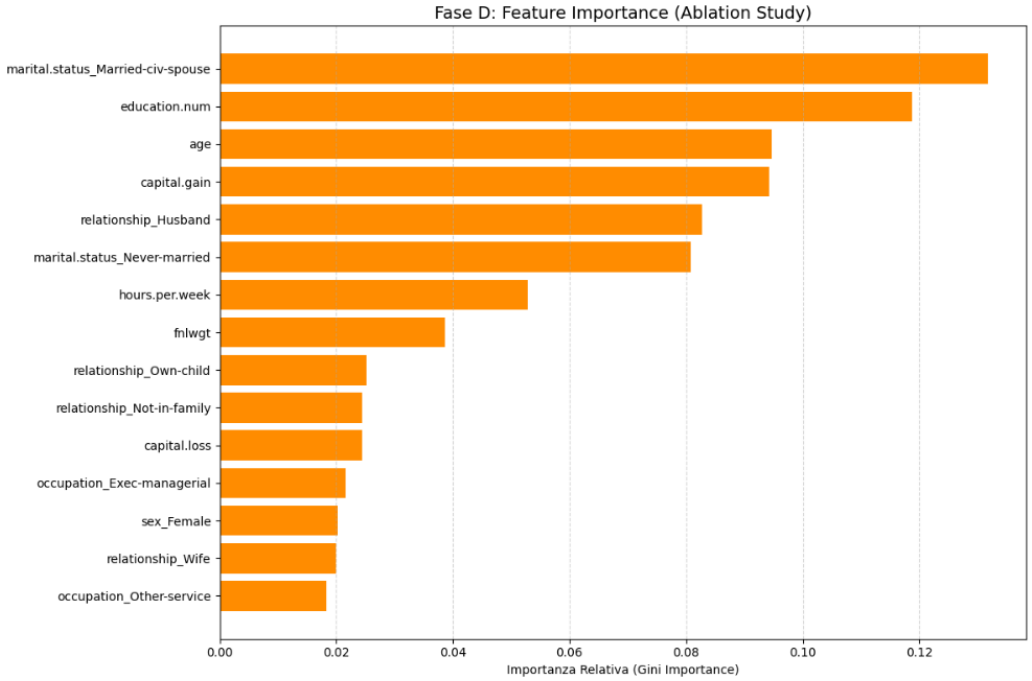

Figura 6: Fase D: Feature Importance – Random Forest Gini Importance. Top 5: `marital.status_Married-civ-spouse`, `education.num`, `capital.gain`, `age`, `hours.per.week`.

4.3 Limitations and Maturity

Il framework si colloca a **TRL 5** (Technology Readiness Level): la pipeline è funzionante, testata su dati reali (UCI Adult, 30.162 istanze) e produce risultati riproducibili, ma non è integrata in un sistema di produzione con deployment e re-training automatico (requisiti TRL 7+). La scala TRL, originariamente sviluppata dalla NASA e adottata da ESA e Commissione Europea, misura la maturità tecnologica su 9 livelli, da TRL 1 (principi di base osservati) a TRL 9 (sistema operativo validato in contesto reale).

Persistono quattro limitazioni strutturali:

Tabella 14: Matrice delle Limitazioni e Technology Readiness Level

Limitazione	**Effetto Critico**	**TRL**	**Mitigazione**
Obsolescenza Dati (1994)	Forte rischio di *data drift*: pattern socio-economici del 1994 non riflettono la realtà attuale	5	Folktables / ACS 2021–2025
Assenza Causalità	Apprendimento di correlazioni storiche, non causali (es. `marital.status` → reddito per correlazione sesso-reddito nel 1994)	3	Grafi causali (DoWhy)
Analisi non intersezionale	DI ed EOD calcolate separatamente per genere e razza, non per $g \times r$ (bias amplificati nascosti)	4	Audit fattoriale 2^k
Alta Dimensionalità	108 feature OHE aumentano overfitting su campioni ridotti e complessità interpretativa	5	Target Encoding / PCA

Obsolescenza Dati (1994) & Forte rischio di *data drift*: I pattern socio-economici del 1994 non riflettono la realtà attuale. Ad esempio, nel censimento del 1994 solo il 55.7% delle donne lavorava, mentre oggi la partecipazione femminile al mercato del lavoro è salita oltre il 70%. Questo disallineamento temporale invalida progressivamente le assunzioni del modello. **Soluzione:** Migrazione su dataset moderni tramite *Folktables* / ACS 2021–2025.

Assenza Causalità & Apprendimento di correlazioni storiche, non causali: Il modello impara che `marital.status` predice il reddito perché nel 1994 questa variabile era fortemente correlata al sesso (89.5% degli sposati erano uomini), non perché lo stato civile causi direttamente il reddito. Questa distinzione è critica: una correlazione storica può scomparire nel tempo, mentre un meccanismo causale resta valido. **Soluzione:** Integrazione di grafi causali tramite libreria *DoWhy* per identificare relazioni causali robuste.

Analisi non intersezionale & DI ed EOD calcolate separatamente: Le metriche di fairness sono misurate separatamente per genere e razza, ma non per la combinazione $g \times r$ (es. donne non-bianche). Questa limitazione nasconde potenziali bias amplificati: una donna bianca e una donna nera potrebbero subire discriminazioni di intensità molto diversa, ma l'analisi attuale non lo rileva. **Soluzione:** Audit fattoriale 2^k per valutare tutte le combinazioni di attributi protetti.

Alta Dimensionalità & 108 feature OHE: Il One-Hot Encoding delle variabili categoriche produce 108 feature, aumentando il rischio di overfitting su campioni ridotti (training set: 24.129 istanze) e rendendo l'interpretazione più complessa. Un numero elevato di feature richiede più dati per generalizzare correttamente. **Soluzione:** Applicare *Target Encoding* (codifica basata sul target) o riduzione dimensionale tramite PCA.

4.4 Future Works

La roadmap verso un'architettura *Fairness-by-Design* a TRL 7+ si articola in quattro interventi concreti, ciascuno mirato a risolvere una specifica limitazione identificata:

1. **SMOTE-NC per il bilanciamento (Pre-processing):** L'ablation study ha dimostrato che la gestione dello sbilanciamento è critica: senza `class_weight='balanced'` la recall crolla del 32% su SVM. **SMOTE-NC** (Synthetic Minority Over-sampling Technique for Nominal and Continuous data) genera istanze sintetiche della classe minoritaria (>50K) rispettando la natura mista del dataset (variabili numeriche e categoriche), permettendo di eliminare la dipendenza dal parametro `class_weight` e migliorare la generalizzazione su distribuzioni più bilanciate.

2. **Fairness Constraints in-processing:** L'attuale approccio misura il bias *dopo* il training (post-hoc). L'evoluzione naturale è integrare il vincolo di equità direttamente nella funzione di perdita durante l'ottimizzazione, rendendo il modello "equo per costruzione":

$$\min_{\theta} \mathcal{L}(\theta) \quad \text{s.t.} \quad \Big| P(\hat{Y} = 1 \mid G = 0) - P(\hat{Y} = 1 \mid G = 1) \Big| \leq \epsilon$$

   Questo approccio, formalizzato da Zafar et al. [5], permetterebbe di superare la soglia EEOC (DI ≥ 0.8) senza rinunciare all'accuracy, bilanciando il trade-off equità-performance tramite il parametro ϵ.

3. **Monitoraggio continuo con PSI e test KS (Post-processing):** Il dataset del 1994 introduce un rischio concreto di *data drift*: i pattern demografici ed economici cambiano nel tempo, invalidando progressivamente le assunzioni del modello. Si prevede l'integrazione di un sistema di monitoraggio basato sul **Population Stability Index (PSI)** – che misura lo shift della distribuzione delle feature – e sul test di **Kolmogorov-Smirnov** per rilevare derive statisticamente significative. Al superamento di una soglia critica (PSI > 0.2), il sistema attiverebbe automaticamente una procedura di re-training.

4. **Migrazione a Folktables / ACS 2021–2025 (Scalabilità):** L'obsolescenza del dataset è la limitazione più critica a livello di TRL. Il framework **Folktables** (Ding et al. [6]) permette di estrarre task di classificazione dai censimenti US ACS aggiornati al 2021–2025, con campioni di oltre 1.2 milioni di istanze. La migrazione consentirebbe: (a) validare la robustezza della pipeline su dati moderni, (b) verificare se il bias strutturale persiste nei dati contemporanei, (c) confrontare i risultati con il benchmark diretto di Ding et al.

Conclusioni Finali

Il presente lavoro ha dimostrato quattro contributi empirici fondamentali:

1. **Validazione Performance:** Accuracy dell'84% con Logistic Regression, coerente con i benchmark della letteratura (Zafar et al. 2019: 0.846; Ding et al. 2021: 0.85) e superiore al majority baseline del 7.6%.

2. **Quantificazione del Bias:** Rilevazione sistematica di violazioni EEOC su entrambi gli attributi protetti (DI Gender = 0.298, DI Race = 0.580 per LR), evidenziando la discriminazione strutturale nei dati del censimento 1994.

3. **Efficacia dell'Ablation:** Dimostrazione empirica che (a) la rimozione di variabili proxy del genere (`marital.status`, `relationship`) peggiora il bias invece di ridurlo (fenomeno di *proxy discrimination*), e (b) il bilanciamento delle classi è condizione necessaria per la correttezza predittiva reale (senza `class_weight='balanced'` la recall crolla del 32%).

4. **Framework TRL 5:** Sviluppo di una pipeline diagnostica end-to-end, deterministica e riproducibile, scalabile e pronta per audit di conformità normativa.

In conclusione, il progetto sancisce la necessità di uno **shift paradigmatico**: dalla pura massimizzazione dell'accuracy a un approccio *fairness-by-design*, dove l'audit etico è parte integrante del ciclo di vita del modello AI.

Supplementary Materials: Codice/dashboard su GitHub, modelli joblib serializzati.

Riferimenti bibliografici

[1] Hardt, M., Price, E., & Srebro, N. (2016). *Equality of Opportunity in Supervised Learning.* NeurIPS.

[2] Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and Machine Learning.* fairmlbook.org.

[3] Mehrabi, N. et al. (2021). A Survey on Bias and Fairness in Machine Learning. *ACM Computing Surveys*, 54(6):1–35.

[4] Lundberg, S. & Lee, S. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS.

[5] Zafar, M. B., Valera, I., Gomez Rodriguez, M., & Gummadi, K. P. (2019). *Fairness Constraints: A Flexible Approach for Fair Classification.* Journal of Machine Learning Research, 20, 1–42.

[6] Ding, F., Hardt, M., Miller, J., & Schmidt, L. (2021). *Retiring Adult: New Datasets for Fair Machine Learning.* NeurIPS